

Previsión de demanda en retail

Qué hace el proyecto, por qué está construido así, y cómo defenderlo en una entrevista técnica.

Repositorio: github.com/marwansaabi/retail-demand-forecasting · **Stack:** Python, LightGBM, pandas, Streamlit, Plotly

1. Qué hace, en 30 segundos

El proyecto predice **cuántas unidades de cada producto se van a vender cada semana, con cuatro semanas de antelación**, a partir del histórico real de ventas de una tienda online. Se entrena un modelo de machine learning (LightGBM) y se compara contra cuatro métodos simples de referencia para comprobar que realmente aporta algo.

Resultado: el modelo gana a la mejor referencia por un **4,8%**. Es un margen modesto, y esa modestia es justo lo que hace creíble el proyecto: en previsión de demanda nadie gana por goleada, y quien lo afirma casi siempre ha filtrado información del futuro en su modelo.

Por qué esto le interesa a una empresa como Inditex

Toda la cadena de suministro del retail depende de esta pregunta. Si predices de más, acumulas stock que acaba en rebajas o se destruye. Si predices de menos, hay rotura de stock y ventas perdidas. Un punto porcentual de mejora en la previsión se traduce en millones de euros en inventario. Es, literalmente, el problema central de datos del sector.

2. Los datos

Se usa el dataset público **Online Retail II** (repositorio UCI): **1.067.371 líneas de factura** reales de una tienda online británica entre diciembre de 2009 y diciembre de 2011. Cada línea es "esta factura, este producto, esta cantidad, este precio, este día".

Limpieza aplicada

Qué se elimina	Por qué
Facturas que empiezan por C	Son cancelaciones, con cantidades negativas. Si se dejan, anulan demanda real.
Cantidades y precios ≤ 0	Ajustes contables, no ventas.
Códigos no-producto (POST, BANK CHARGES...)	Portes, comisiones y ajustes manuales; no son artículos de catálogo.

Tras limpiar quedan 1.036.877 líneas. Se agregan a **unidades por producto y semana** y se conservan las 50 referencias de mayor volumen: **5.200 observaciones sobre 104 semanas completas**.

3. Las tres decisiones que definen el proyecto

Estas tres son las que de verdad determinaron el resultado, mucho más que la elección del algoritmo. Si te preguntan algo en una entrevista, será sobre esto.

3.1. Semanal, no diario

El primer intento fue predecir demanda **diaria**. Falló, y el diagnóstico fue revelador: este negocio es **mayorista**. La mediana son 12 unidades al día, pero el máximo es de **80.995 unidades en un solo día** — un único cliente haciendo un pedido enorme. El **0,4% de los días concentra el 21% del volumen total**.

Ningún modelo puede adivinar, desde el histórico de ventas, el día exacto en que un cliente decide hacer un pedido de 80.000 unidades. A escala diaria eso es ruido irreducible. Al agregar a semanal, ese ruido de *timing* se absorbe, y además coincide con cómo se planifica el reaprovisionamiento en la realidad.



La misma referencia a las dos escalas. Arriba, picos de pedidos individuales imposibles de anticipar; abajo, la señal que sí tiene estructura aprendible.

3.2. Las semanas sin ventas son ceros, no huecos

El registro de facturas solo contiene los días en que hubo venta. Si un producto no se vendió una semana, esa semana simplemente no aparece. Pero **no vender nada no es un dato ausente: es un cero**. Dejarlo como hueco inflaría al alza todas las medias móviles y sesgaría el modelo entero. El 12% de las observaciones son ceros explícitos añadidos en la preparación.

3.3. El objetivo se modela como $\log(1+\text{unidades})$

Con el objetivo en su escala original, el modelo **perdía** contra una simple media móvil (WMAPE 0,62 frente a 0,59). La distribución de demanda está muy sesgada a la derecha: unas pocas semanas con pedidos enormes dominan la función de pérdida y arrastran hacia arriba todas las demás predicciones. Transformar el objetivo con logaritmo (y deshacer la transformación al predecir) fue lo que dio la vuelta al resultado.

El detalle metodológico que más vale en una entrevista

Esa decisión se tomó midiendo sobre un **periodo de desarrollo separado** (nov 2010 – mar 2011), no sobre el periodo de test que se reporta. Elegir configuraciones mirando el test es la versión sutil de entrenar sobre el test: infla el resultado y no se sostiene en producción. En el periodo de desarrollo, log obtuvo 0,768 frente a 0,803 — por eso se eligió.

4. Cómo funciona el modelo

Se usa **LightGBM**, un algoritmo de *gradient boosting*: construye cientos de árboles de decisión pequeños, cada uno corrigiendo los errores del anterior. Es el estándar de facto en previsión de demanda tabular.

Un solo modelo global para todos los productos

En lugar de entrenar 50 modelos (uno por referencia), se entrena **uno solo** con todas, incluyendo la identidad del producto como una variable categórica más. El motivo: cada serie tiene solo ~100 semanas, que es muy poco. Al juntarlas, un producto de poca rotación puede aprovechar el patrón estacional aprendido de los productos con mucha venta.

Las variables (features)

Grupo	Qué contiene
Retardos	Unidades vendidas hace 1, 2, 3, 4, 8, 13 y 52 semanas
Ventanas móviles	Media, desviación típica y proporción de ceros a 4, 8, 13 y 26 semanas
Tendencia	Media de 4 semanas dividida entre la de 13; mismo periodo del año anterior
Señales de mercado	Precio, nº de facturas y nº de clientes: último valor, media de 4 semanas, y ratio frente a su norma de 13 semanas
Calendario	Mes, trimestre, semana del año y del mes, festivos británicos en la semana, semanas hasta Navidad, codificaciones cíclicas seno/coseno
Horizonte	Qué paso se está prediciendo (1 a 4), para que un mismo modelo module su incertidumbre según la distancia

El ratio de precio frente a su propia norma de 13 semanas es lo más parecido a un indicador de promoción que permiten estos datos: un producto que cotiza por debajo de su precio habitual suele estar en campaña.

5. Cómo se valida (la parte crítica)


La regla que gobierna todo el código

Una variable que describe la semana objetivo **solo puede usar información disponible en el momento de hacer la previsión**. Los retardos y las medias móviles se leen siempre en el origen de previsión, nunca en la semana que se quiere predecir. La única excepción son los datos de calendario, porque de verdad se conocen de antemano: hoy ya sabemos que Navidad cae en la semana 52.

Saltarse esto es la forma clásica de construir un modelo con un backtest espectacular y cero capacidad predictiva real.

Backtesting de origen móvil

Una única división entrenamiento/test en una serie temporal te informa sobre el tiempo que hizo un mes concreto. En su lugar se avanzan **8 orígenes de previsión** por el calendario, separados 4 semanas, prediciendo 4 semanas cada vez. En cada origen **el modelo se reentrena desde cero** usando únicamente los datos anteriores a ese punto.




Cada fila es un fold. El bloque gris es lo que el modelo puede ver; el azul, las 4 semanas que debe predecir sin haberlas visto nunca.

6. Las métricas, explicadas

Métrica	Qué mide	Por qué está aquí
wMAPE	Error absoluto total dividido entre la demanda total. Un 55,8% significa que la suma de errores equivale al 55,8% de las unidades realmente vendidas.	Es la que se usa en planificación de demanda. El MAPE clásico se dispara al infinito con las semanas de venta cero, y aquí el 12% lo son.
MASE	Error dividido por el del método ingenuo ("la próxima semana será como esta") medido dentro del entrenamiento.	Por debajo de 1 significa que bates a ese método ingenuo. Es comparable entre productos de volúmenes muy distintos.
MAE	Error medio en unidades, sin signo.	Interpretable directamente en unidades de producto.
RMSE	Como el MAE pero penalizando mucho más los errores grandes.	Se reporta por transparencia, no como titular: aquí está dominado por un puñado de pedidos mayoristas.

7. Resultados

Modelo	MAE	RMSE	wMAPE	MASE
LightGBM	219,5	456,2	55,8%	0,783
Media móvil (13 sem.)	230,6	449,4	58,6%	0,829
Media móvil (4 sem.)	233,1	444,4	59,2%	0,809
Ingenuo (última semana)	290,9	530,5	73,9%	0,988
Ingenuo estacional (52 sem.)	362,1	772,0	92,0%	1,237



Cómo interpretarlo con honestidad

El modelo gana en MAE, wMAPE y MASE. **Pierde en RMSE** frente a las medias móviles, y eso no es un descuido: la transformación logarítmica impide deliberadamente que el modelo persiga los pedidos gigantes, lo que cuesta error cuadrático y compra precisión en el 99% de semanas normales. Saber explicar ese compromiso vale más que ocultarlo.

El ingenuo estacional (comparar con la misma semana del año anterior) es con diferencia el peor. Tiene sentido: con solo dos años de datos, la referencia interanual es una sola observación por semana, demasiado ruidosa para fiarse de ella.

8. El código, archivo por archivo

Archivo	Responsabilidad
<code>data/prepare_data.py</code>	Del Excel bruto al panel semanal limpio: limpieza, agregación, ceros explícitos, descarte de semanas parciales.
<code>utils/features.py</code>	Construcción de variables. Todo indexado por posición de periodo, no por días, así que funciona igual en diario o semanal.
<code>utils/models.py</code>	Los cuatro métodos de referencia y la clase del modelo LightGBM.
<code>utils/backtest.py</code>	Validación de origen móvil y cálculo de las cuatro métricas.
<code>run_backtest.py</code>	Reproduce la tabla de resultados y cachea la salida.
<code>app.py</code>	Dashboard en Streamlit: comparativa, previsión por producto, importancia de variables y metodología.

El backtest es **determinista**: dos ejecuciones seguidas producen exactamente los mismos números. Está verificado.

9. Preguntas que te pueden hacer, y cómo responderlas

Estas son las preguntas razonables que haría alguien técnico al leer el proyecto. Vale la pena que las respuestas sean tuyas, no memorizadas.

"Solo mejoras un 4,8% sobre una media móvil. ¿Merece la pena?"

Sí, y hay dos motivos. Primero, a escala de un retailer grande ese porcentaje sobre el inventario total es mucho dinero. Segundo, y más importante: ese 4,8% es real. Las referencias contra las que compito no son de paja — una media móvil de 13 semanas es un rival duro cuando la demanda es un nivel que deriva lentamente más ruido. Un proyecto que presumiera de un 90% de mejora estaría casi con seguridad filtrando datos.

"¿Cómo sabes que no hay fuga de datos?"

Por construcción. Las variables de histórico se calculan sobre una serie truncada en el origen de previsión: la función que las construye físicamente no recibe datos posteriores. Las de calendario sí describen la semana objetivo, pero son conocibles de antemano. Y en cada uno de los 8 folds el modelo se reentrena desde cero solo con datos anteriores al origen.

"¿Por qué LightGBM y no una red neuronal o ARIMA?"

ARIMA modela una serie cada vez, y aquí cada serie tiene solo ~100 puntos: muy poco, y además no aprovecha lo que comparten las 50 referencias. Una red neuronal necesitaría bastante más volumen de datos para justificarse. El gradient boosting sobre variables tabulares es el punto óptimo para este tamaño, y es lo que se usa en la industria para esto.

"¿Qué harías si tuvieras que llevarlo a producción?"

Tres cosas. Predecir intervalos en vez de un valor puntual, porque una decisión de reposición necesita un cuantil asociado a un nivel de servicio, no una media. Reconciliación jerárquica: el total es mucho más predecible que cualquier producto individual, así que prever arriba y repartir hacia abajo suele batir al enfoque bottom-up. Y modelos específicos de demanda intermitente (Croston, TSB) para la cola larga de referencias que solo venden algunas semanas.

"¿Qué te limitó más?"

La ausencia de variables explicativas de verdad. No hay datos de promociones, ni de campañas, ni de competencia, ni de stock disponible. Reconstruí una señal aproximada de promoción con el ratio del precio frente a su norma de 13 semanas, pero es un sustituto pobre. Con datos reales de promoción y de precio planificado, el margen sobre las referencias sería bastante mayor.

"¿Por qué el modelo pierde en RMSE?"

Porque es una consecuencia buscada de modelar en escala logarítmica. El RMSE castiga mucho los errores grandes, y los errores grandes aquí son los pedidos mayoristas atípicos. Al no perseguirlos, acierto más en las semanas normales y fallo por más en esas pocas. Dado que el objetivo es planificar reposición, prefiero ese compromiso.

10. Limitaciones honestas

Limitación	Implicación
Solo 104 semanas de histórico	Apenas dos ciclos anuales. La estacionalidad interanual se estima con muy pocos datos, y por eso el ingenuo estacional rinde tan mal.
Datos mayoristas, no de tienda física	El patrón de pedidos grandes y esporádicos no es el mismo que el de una tienda de retail al consumidor final.
Sin promociones ni precio planificado	En la industria el precio futuro se conoce (lo fijas tú). Aquí solo se puede usar el precio pasado.
50 referencias, las de más volumen	La cola larga de productos con venta esporádica se comporta distinto y necesitaría modelos específicos.

Marwan El Saabi · github.com/marwansaabi/retail-demand-forecasting · Datos: UCI Online Retail II